

## Trabajo.1: Programación

Fecha límite de entrega: 5 de Abril

Valoración máxima: 12 puntos

---

### NORMAS DE DESARROLLO Y ENTREGA DE TRABAJOS

Para este trabajo como para los demás es obligatorio presentar un informe escrito con las valoraciones y decisiones adoptadas en el desarrollo de cada uno de los apartados. Incluir en el informe los gráficos generados. También deberá incluirse una valoración sobre la calidad de los resultados encontrados. (obligatorio en pdf). **Sin este informe se considera que el trabajo NO ha sido presentado.**

**Normas para el desarrollo de los Trabajos:** EL INCUMPLIMIENTO DE ESTAS NORMAS SIGNIFICA PERDIDA DE 2 PUNTOS POR CADA INCUMPLIMIENTO.

- El código de cada ejercicio/apartado de la práctica se debe estructurar en un script Python incluyendo las funciones que se hayan definido. Cada script debe incluirse en un fichero distinto.
- Todos los resultados numéricos o gráficas serán mostrados por pantalla, parando la ejecución después de cada apartado. EL código NO DEBE escribir nada a disco.
- El path que se use en la lectura de cualquier fichero auxiliar de datos debe ser siempre "datos/nombre\_fichero". Es decir, se espera que el código lea de un directorio llamado "datos", situado dentro del directorio donde se desarrolla y se ejecuta la práctica.
- Un código es apto para ser corregido si se puede ejecutar de principio a fin sin errores.
- NO ES VÁLIDO usar opciones en las entradas. Para ello fijar al comienzo los parámetros por defecto que considere que son los óptimos.
- El código debe estar obligatoriamente comentado explicando lo que realizan los distintos apartados y/o bloques.
- Poner puntos de parada para mostrar imágenes o datos por consola.
- Todos los ficheros (\*.py, \*.pdf) se entregan juntos dentro de un único fichero zip, sin ningún directorio que los contenga.
- ENTREGAR SOLO EL CODIGO FUENTE, NUNCA LOS DATOS.
- **Forma de entrega:** Subir a PRADO.

¿Que debemos obtener en el ejercicio 1? La función E es f

Hay que aplicar la ecuación

el valor de la función debe ir bajando

## 1. EJERCICIO SOBRE LA BÚSQUEDA ITERATIVA DE ÓPTIMOS

La actualización de los W deben ser simultanea, se actualizan

- (1 punto) Implementar el algoritmo de gradiente descendente.
- (2 puntos) Considerar la función  $E(u, v) = (u^3 e^{(v-2)} - 2v^2 e^{-u})^2$ . Usar gradiente descendente para encontrar un mínimo de esta función, comenzando desde el punto  $(-1, 1)$  usando una tasa de aprendizaje  $\eta = 0,1$ .
  - Calcular el valor de la función y mostrar la expresión del gradiente de la función  $E(u, v)$
  - ¿Cuántas iteraciones tarda el algoritmo en obtener por primera vez un valor de  $E(u, v)$  inferior a  $10^{-14}$ ? (Usar notación de bits)
  - ¿En qué coordenadas  $(u, v)$  se alcanzó por primera vez un valor igual o menor a  $10^{-14}$  en el apartado anterior.
- (2 puntos) Considerar ahora la función  $f(x, y) = (x + 2)^2 + 2(y - 2)^2 + 2 \sin(2\pi x) \sin(2\pi y)$ 
  - Usar gradiente descendente para minimizar esta función. Usar como punto inicial  $(x_0 = -1, y_0 = 1)$ , tasa de aprendizaje  $\eta = 0,01$  y un máximo de 100 iteraciones. Generar un gráfico de cómo desciende el valor de la función con las iteraciones. Repetir el experimento pero usando  $\eta = 0,1$ , comentar las diferencias y su dependencia de  $\eta$ .
  - Obtener el valor mínimo y los valores de las variables  $(x, y)$  en donde se alcanzan cuando el punto de inicio se fija en:  $(-0,5, -0,5), (1, 1), (2, 1, -2, 1), (-3, 3), (-2, 2)$ . Generar una tabla con los valores obtenidos. Comentar la dependencia del punto inicial.
- (1.5 punto) ¿Cuál sería su conclusión sobre la verdadera dificultad de encontrar el mínimo global de una función arbitraria?

este primer ejercicio no hace falta

con la memoria

Tarda poco, con 10 iteraciones

Mirar pantallazo, como

No se pide el resultado en 3D,

En la memoria es donde se deben expresar

## 2. EJERCICIO SOBRE REGRESIÓN LINEAL (5.5 PUNTOS)

Este ejercicio ajusta modelos de regresión a vectores de características extraídos de imágenes de dígitos manuscritos. En particular se extraen dos características concretas que miden: el valor medio del nivel de gris y la simetría del número respecto de su eje vertical. Solo se seleccionarán para este ejercicio las imágenes de los números 1 y 5.

- (2.5 puntos) Estimar un modelo de regresión lineal a partir de los datos proporcionados por los vectores de características  $x_1$  y  $x_2$ . Usar el algoritmo de mínimos cuadrados ordinarios (OLS) o el algoritmo de la pseudo-inversa de Moore-Penrose. Las etiquetas serán  $\{-1, 1\}$ , una por cada muestra. Guardar los resultados obtenidos en un fichero llamado `regression_results.txt` junto con los datos de entrenamiento. (Usar `E_in` y `E_out` (para `E_out` calcular las predicciones usando los datos del fichero de test). ( usar `simula_unif` como llamada para la función (opcional)).
- (3 puntos) En este apartado exploramos como se transforman los errores  $E_{in}$  y  $E_{out}$  cuando aumentamos la complejidad del modelo lineal usado. Ahora hacemos uso de la función `simula_unif(N, 2, size)` que nos devuelve  $N$  coordenadas 2D de puntos uniformemente muestreados dentro del cuadrado definido por  $[-size, size] \times [-size, size]$

Cuando creas I

el apartado 1 es más o menos como la diapositiva

no hacer caso a este R

■ EXPERIMENTO:

Como escoger I

Todos los pesos se actualizan a la vez

2

2.1 división de un espacio

$$y = w_0 + w_1 * x_1 + w_2 * x_2 + \dots$$

le pasamos x, y, learning rate, número

Nuestros parámetros son  $[w_0, w_1, b]$

$h(x_n) = x_n \cdot \text{dot}(w)$

El  $w$  inicial puede ser todo ceros

Podemos usar 500 ó 1000 iteraciones

Generar una muestra de entrenamiento de  $N = 1000$  puntos en el cuadrado  $[-1, 1] \times [-1, 1]$ . Pintar el mapa de puntos 2D. (ver función de ayuda)

b) Consideremos la función  $f(x_1, x_2) = \text{sign}((x_1 - 0.2)^2 + x_2^2 - 0.6)$  que usaremos para asignar una etiqueta a cada punto de la muestra anterior. Introducir la etiqueta  $y$  a cada punto. (en numpy hay una función `sign`)

época es cuando tu modelo ve todos los datos

Introducir las etiquetas cambiando aleatoriamente el  $10\%$  de las etiquetas en cada época. Este  $10\%$  se debe cambiar en cada época. Pintar el mapa de etiquetas obtenido.

c) Usando como vector de características  $(1, x_1, x_2)$  ajustar un modelo de regresión lineal al conjunto de datos generado y estimar los pesos  $w$ . Estimar el error de ajuste  $E_{\text{in}}$  usando Gradiente Descendente Estocástico (SGD).

Pintar  $\text{train}$  y  $\text{test}$

d) Ejecutar todo el experimento definido por (a)-(c) 1000 veces (generamos 1000 muestras diferentes) y

- Calcular el valor medio de los errores  $E_{\text{in}}$  de las 1000 muestras.
- Generar 1000 puntos nuevos por cada iteración y calcular con ellos el valor de  $E_{\text{out}}$  en dicha iteración. Calcular el valor medio de  $E_{\text{out}}$  en todas las iteraciones.

La recta de decisión

e) Valor que tan bueno considera que es el ajuste con este modelo lineal a la vista de los valores medios obtenidos de  $E_{\text{in}}$  y  $E_{\text{out}}$

- Repetir el mismo experimento anterior pero usando características no lineales. Ahora usaremos el siguiente vector de características:  $\Phi_2(x) = (1, x_1, x_2, x_1x_2, x_1^2, x_2^2)$ . Ajustar el nuevo modelo de regresión lineal y calcular el nuevo vector de pesos  $\hat{w}$ . Calcular los errores promedio de  $E_{\text{in}}$  y  $E_{\text{out}}$ .
- A la vista de los resultados de los errores promedios  $E_{\text{in}}$  y  $E_{\text{out}}$  obtenidos en los dos experimentos ¿Qué modelo considera que es el más adecuado? Justifique la decisión.

Las gráficas

## 2.1. BONUS

El BONUS solo se tendrá en cuenta si se ha obtenido al menos el 75% de los puntos de la parte obligatoria.

1. (2 puntos) **Método de Newton** Implementar el algoritmo de minimización de Newton y aplicarlo a la función  $f(x, y)$  dada en el ejercicio 3. Desarrolle los mismos experimentos usando los mismos puntos de inicio.
  - Generar un gráfico de como descende el valor de la función con las iteraciones.
  - Extraer conclusiones sobre las conductas de los algoritmos comparando la curva de decrecimiento de la función calculada en el apartado anterior y la correspondiente obtenida con gradiente descendente.